




## 6.2 隐马尔可夫模型



产生隐马尔可夫链模型



## 6.3 独立增量过程

### 1、独立增量过程 (independence of increments)

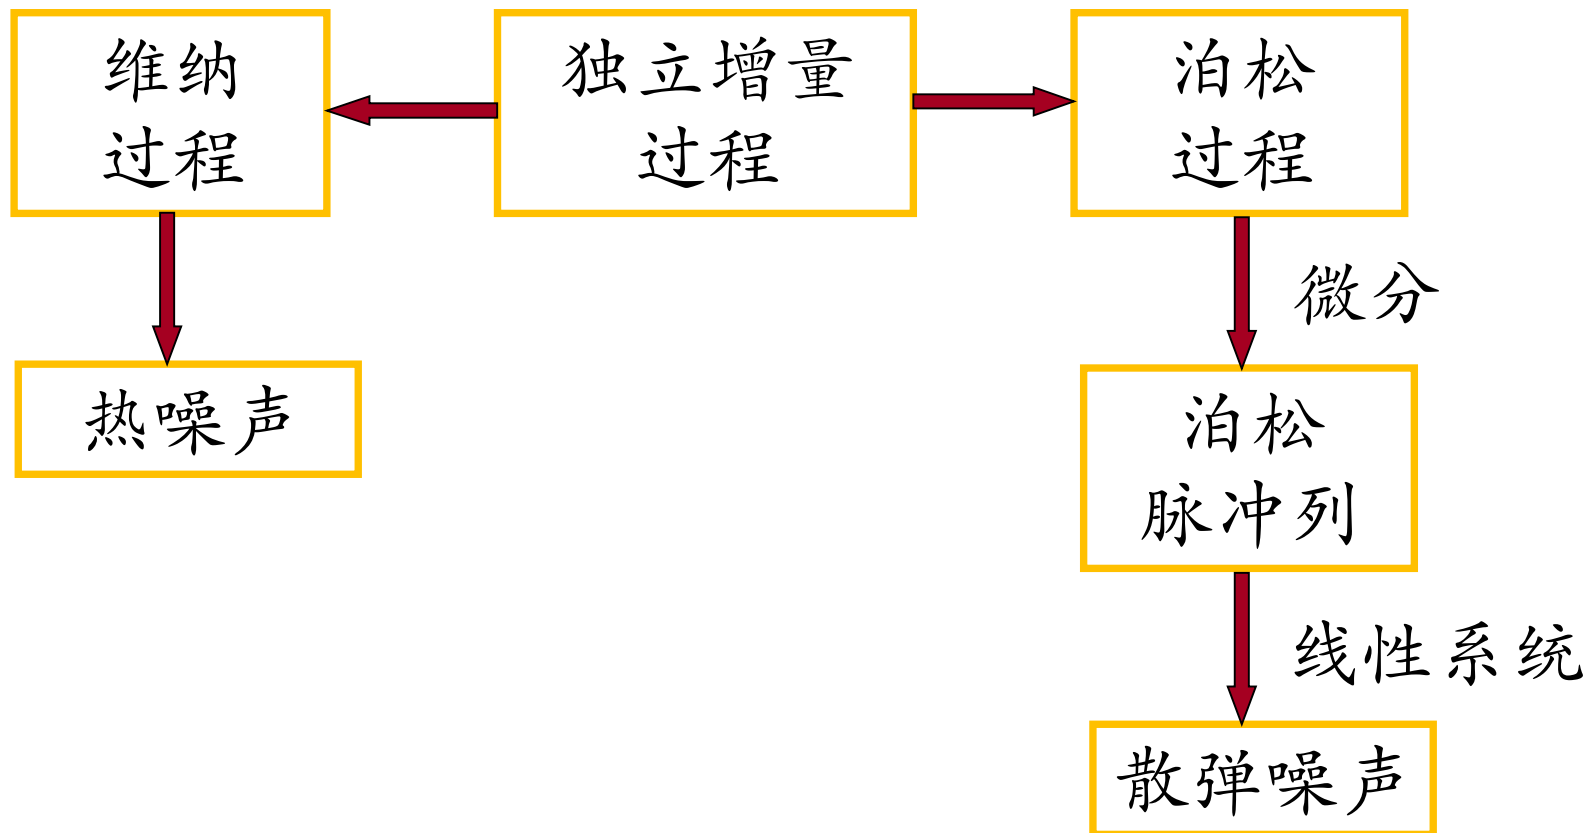
设随机过程  $X(t)$ ,  $t \geq 0$  满足

$$(1) \quad P[X(t_0) = 0] = 1$$

$$(2) \quad \text{对任意的时刻 } 0 \leq t_0 < t_1 < \cdots < t_n < b$$

过程的增量  $X(t_1) - X(t_0)$ 、 $\cdots$ 、 $X(t_n) - X(t_{n-1})$

是相互独立的随机变量, 则称  $X(t)$  为**独立增量过程**, 又称**可加过程**。





## 2、泊松过程 (齐次的)

泊松过程  $\{X(t), t \geq 0\}$  在时间间隔  $[t_0, t_0+t]$  内  $k$  次出现事件  $A$  的概率为:

$$P\{X(t_0+t) - X(t_0) = k\} \triangleq P_k(t_0, t_0+t) = \frac{(\lambda t)^k}{k!} e^{-\lambda t}$$

### 泊松脉冲列

设有脉冲随机出现过程  $Z(t)$ ，脉冲出现是相互独立的，即

$$Z(t) = \sum_i \delta(t - t_i) \quad \longleftrightarrow \quad Z(t) = \frac{d}{dt} X(t)$$

$Z(t)$  称为泊松脉冲列。



中山大學  
SUN YAT-SEN UNIVERSITY

# 复习

## 散弹噪声

☞ 线性系统输入端为泊松脉冲序列 $Z(t)$ ，则系统的输出


为散弹噪声，即：
$$S(t) = \sum_i h(t - t_i)$$

### 3、维纳过程（热噪声）

## 第七章 估计理论



## 7.1 估计的基本概念



参量估计的统计推断模型

### 估计基本要素

- 参数空间
- 概率传递机制
- 观测空间
- 估计准则
- 估计空间



## 7.2 贝叶斯估计 (掌握)



频率派与贝叶斯派之争：  
比较ML 和 MAP

$$p(\theta | z) = \frac{p(z | \theta) p(\theta)}{p(z)}$$

$$p(\theta | z) \propto p(z | \theta) p(\theta)$$

posterior    likelihood    prior

- MLE（频率学派）认为参数  $\theta$  是一个未知的常量，需要从数据中估计出来。MAP（贝叶斯学派）认为参数  $\theta$  是一个随机变量，服从一个概率分布，应该充分利用先验概率。
- MLE的缺点是如果数据集太小会出现过拟合，或者严重偏差；MAP的缺点是使用不同的先验会得到不同的结果。



中山大學  
SUN YAT-SEN UNIVERSITY

习题:

7.3

7.4

7.6





## 1、贝叶斯估计

在估计某个量时，噪声的影响使估计产生误差，估计误差是要付出代价的，这种代价可以用代价函数来加以描述，记为 $c(\theta, \hat{\theta}) = c(\theta - \hat{\theta}) = c(\tilde{\theta})$ 。贝叶斯估计准则就是在已知代价函数及先验概率基础上，使估计付出的平均代价最小。

设观测值为 $z$ ，待估参量为 $\theta$

估计误差： $\tilde{\theta} = \theta - \hat{\theta}(z)$

$$\hat{\theta}(z) \leftarrow \min_{\hat{\theta}} E[C(\tilde{\theta})]$$



## 7.2 贝叶斯估计

统计平均代价:

$$\begin{aligned} E[C(\tilde{\theta})] &= E[C(\theta, \hat{\theta}(z))] \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} C(\theta, \hat{\theta}(z)) f(\theta, z) d\theta dz \\ &= \int_{-\infty}^{\infty} \left[ \int_{-\infty}^{\infty} C(\theta, \hat{\theta}(z)) f(\theta | z) d\theta \right] f(z) dz \\ &= \int_{-\infty}^{\infty} \bar{C}(\theta | z) f(z) dz \end{aligned}$$

条件平均代价

等价于使下式最小:


$$\int_{-\infty}^{\infty} C(\theta, \hat{\theta}(z)) f(\theta | z) d\theta = \text{最小}$$




## 7.2 贝叶斯估计

### 2、典型代价函数及贝叶斯估计


平方代价:  $C(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$



绝对值代价:  $C(\theta, \hat{\theta}) = |\theta - \hat{\theta}|$




均匀代价:  $C(\theta, \hat{\theta}) = \begin{cases} 1, & |\theta - \hat{\theta}| \geq \frac{\Delta}{2} \\ 0, & |\theta - \hat{\theta}| < \frac{\Delta}{2} \end{cases}$





## 7.2 贝叶斯估计

平方代价:  $C(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$



👉 最小均方估计(Minimal Square)

$$\bar{C}(\theta | z) = \int_{-\infty}^{\infty} (\theta - \hat{\theta})^2 f(\theta | z) d\theta = \text{最小}$$

对  $\hat{\theta}$  求导数, 并使其等于零:

$$\frac{d\bar{C}(\theta | z)}{d\hat{\theta}} = -2 \int_{-\infty}^{\infty} \theta f(\theta | z) d\theta + 2\hat{\theta} \int_{-\infty}^{\infty} f(\theta | z) d\theta$$


得:  $\hat{\theta} = \int_{-\infty}^{\infty} \theta f(\theta | z) d\theta$

即  $\hat{\theta} = E[\theta | z]$ , 也称为条件均值估计。



## 7.2 贝叶斯估计

绝对值代价:  $C(\theta, \hat{\theta}) = |\theta - \hat{\theta}|$



👉 条件中位数估计 (Median)

$$\begin{aligned}\bar{C}(\theta | z) &= \int_{-\infty}^{\infty} |\theta - \hat{\theta}| f(\theta | z) d\theta \\ &= \int_{-\infty}^{\hat{\theta}} (\hat{\theta} - \theta) f(\theta | z) d\theta + \int_{\hat{\theta}}^{\infty} (\theta - \hat{\theta}) f(\theta | z) d\theta\end{aligned}$$

对  $\hat{\theta}$  求导数, 并使其等于零, 得:


$$\int_{-\infty}^{\hat{\theta}_{abs}} f(\theta | z) d\theta = \int_{\hat{\theta}_{abs}}^{\infty} f(\theta | z) d\theta$$

可见, 估计为条件概率密度  $f(\theta | z)$  的中位数。



## 7.2 贝叶斯估计

均匀代价: 
$$C(\theta, \hat{\theta}) = \begin{cases} 1, & |\theta - \hat{\theta}| \geq \frac{\Delta}{2} \\ 0, & |\theta - \hat{\theta}| < \frac{\Delta}{2} \end{cases}$$



👉 最大后验概率估计 (maximal posterior probability)

$$\bar{C}(\theta | z) = 1 - \int_{\hat{\theta}_{map} - \frac{\Delta}{2}}^{\hat{\theta}_{map} + \frac{\Delta}{2}} f(\theta | z) d\theta$$

应当选择  $\hat{\theta}$  , 使它处在后验概率  $f(\theta | z)$  的最大处。

最大后验概率方程:

$$\left. \frac{\partial f(\theta | z)}{\partial \theta} \right|_{\theta = \hat{\theta}_{map}} = 0 \text{ 或 } \left. \frac{\partial \ln f(\theta | z)}{\partial \theta} \right|_{\theta = \hat{\theta}_{map}} = 0$$



## 7.2 贝叶斯估计

由关系式: 
$$f(\theta | z) = \frac{f(z | \theta) f(\theta)}{f(z)}$$

两边取对数并对 $\theta$ 求导, 得最大后验概率方程的另一形式:

$$\left[ \frac{\partial \ln f(z | \theta)}{\partial \theta} + \frac{\partial \ln f(\theta)}{\partial \theta} \right] \bigg|_{\theta = \hat{\theta}_{map}} = 0$$



## 7.2 贝叶斯估计

**例7.2** 设观测为  $z = A + v$ ，其中被估计量  $A$  在  $[-A_0, A_0]$  上**均匀分布**，测量噪声  $v \sim N(0, \sigma_v^2)$ ，求  $A$  的最大后验概率估计和最小均方估计。

解： 最大后验概率估计

$$f(A | z) = \frac{f(z | A)f(A)}{f(z)}$$

$$f(z | A) = \frac{1}{\sqrt{2\pi}\sigma_v} \exp\left\{-\frac{(z - A)^2}{2\sigma_v^2}\right\} \quad f(A) = \begin{cases} \frac{1}{2A_0} & -A_0 \leq A \leq A_0 \\ 0 & \text{其他} \end{cases}$$





## 7.2 贝叶斯估计

当  $-A_0 \leq z \leq A_0$ ， $f(A|z)$  的最大值出现在  $A=z$  处，所以，  
 $\hat{A}_{map} = z$ ，当  $z > A_0$  时， $f(A|z)$  的最大值出现在  $A=A_0$  处，  
 $\hat{A}_{map} = A_0$ ，当  $z < -A_0$  时， $f(\theta|z)$  的最大值出现在  $A=-A_0$  处，  
 $\hat{A}_{map} = -A_0$ ，即

$$\hat{A}_{map} = \begin{cases} -A_0 & z < -A_0 \\ z & -A_0 \leq z \leq A_0 \\ A_0 & z > A_0 \end{cases}$$

再看最小均方估计：



## 7.2 贝叶斯估计

$$\begin{aligned}\hat{A}_{ms} &= E(A | z) = \int_{-\infty}^{\infty} A f(A | z) dA = \int_{-\infty}^{\infty} A \frac{f(z | A) f(A)}{f(z)} dA \\&= \frac{\int_{-\infty}^{\infty} A f(z | A) f(A) dA}{\int_{-\infty}^{\infty} f(z | A) f(A) dA} = \frac{\int_{-A_0}^{A_0} \frac{A}{\sqrt{2\pi}\sigma_v} \exp\left[-\frac{(z-A)^2}{2\sigma_v^2}\right] \cdot \frac{1}{2A_0} dA}{\int_{-A_0}^{A_0} \frac{1}{\sqrt{2\pi}\sigma_v} \exp\left[-\frac{(z-A)^2}{2\sigma_v^2}\right] \cdot \frac{1}{2A_0} dA} \\&= \frac{\int_{z-A_0}^{z+A_0} (z-u) \cdot \exp\left[-\frac{u^2}{2\sigma_v^2}\right] du}{\int_{z-A_0}^{z+A_0} \exp\left[-\frac{u^2}{2\sigma_v^2}\right] du}\end{aligned}$$



## 7.2 贝叶斯估计

$$\left( = Z - \frac{2\sigma_v^2 \int_{(x-a)/\sqrt{2}}^{(x+a)/\sqrt{2}} u \exp[-u^2] du}{\sigma_v \int_{x-a}^{x+a} \exp\left[-\frac{u^2}{2}\right] du} \right)$$

$$= Z - \frac{2\sigma_v^2 \int_{(x-a)/\sqrt{2}}^{(x+a)/\sqrt{2}} s \exp[-s^2] ds}{\sigma_v \int_{x-a}^{x+a} \exp\left[-\frac{t^2}{2}\right] dt}$$

$$s = \frac{u}{\sqrt{2}\sigma_v}$$

$$t = \frac{u}{\sigma_v}$$


$$= Z - \frac{\sigma_v \left\{ \exp[-(x-a)^2 / 2] - \exp[-(x+a)^2 / 2] \right\}}{\sqrt{2\pi} [Q(x-a) - Q(x+a)]}$$



## 7.2 贝叶斯估计

$Q(\cdot)$  为标准正态概率密度函数的概率右尾函数,

$$Q(x) = \frac{1}{\sqrt{2\pi}} \int_x^{\infty} \exp(-u^2 / 2) du$$





## 7.2 贝叶斯估计

例7.3 高斯白噪声中的直流电平估计-高斯先验分布。设有N次独立观测  $z_i = A + v_i$  ,  $i = 1, 2, \dots, N$  , 其中  $v \sim N(0, \sigma^2)$  ,  $A \sim N(\mu_A, \sigma_A^2)$  , 求A的估计。 【阅读P204】

解 先求后验概率密度:

$$\begin{aligned} f(A|\mathbf{z}) &= \frac{f(\mathbf{z}|A)f(A)}{\int_{-\infty}^{\infty} f(\mathbf{z}|A)f(A)dA} \\ &= \dots \\ &= \frac{1}{\sqrt{2\pi\sigma_{A|z}^2}} \exp \left[ -\frac{1}{2\sigma_{A|z}^2} (A - \mu_{A|z})^2 \right] \end{aligned} \quad (23)$$



## 7.2 贝叶斯估计

由(23)可以看出，后验概率密度是高斯的。由于最小均方估计为被估计量的条件均值，所以

$$\hat{A}_{ms} = \mu_{A|z} = \left( \frac{N}{\sigma^2} \bar{z} + \frac{\mu_A}{\sigma_A^2} \right) \sigma_{A|z}^2 = \frac{\frac{N}{\sigma^2} \bar{z} + \frac{\mu_A}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} \quad (24)$$

令  $k = \frac{\sigma_A^2}{\sigma_A^2 + \sigma^2/N}$ ，则

体会

$$\hat{A}_{ms} = k \bar{z} + (1 - k) \mu_A \quad (25)$$

另外，由于最大后验概率估计是使后验概率最大对应的A值，因此，由(23)式可得  $\hat{A}_{map} = \mu_{A|z} = \hat{A}_{ms}$  (26)

即最大后验概率估计与最小均方估计相等。



### 1、最大似然估计 (Maximum Likelihood Estimate)

由最大后验概率估计

$$\left[ \frac{\partial \ln f(z | \theta)}{\partial \theta} + \frac{\partial \ln f(\theta)}{\partial \theta} \right] \bigg|_{\theta = \hat{\theta}_{map}} = 0$$

若先验概率密度函数  $f(\theta)$  未知，则由左边第一项求解参量 $\theta$ ，即最大似然估计，用  $\hat{\theta}_{mL}$  表示。最大似然方程为：

$$\frac{\partial \ln f(z | \theta)}{\partial \theta} \bigg|_{\theta = \hat{\theta}_{mL}} = 0$$



## 7.3 最大似然估计

例7.4 高斯白噪声中的直流电平估计-未知参数。设有N次独立观测 $z_i = A + v_i$ ， $i=1,2,\dots,N$ ，其中 $v_i \sim N(0, \sigma^2)$ ，**A为未知参数， $\sigma^2$ 已知**，求A的最大似然估计。

【解】 
$$f(\mathbf{z} | A) = \left( \frac{1}{2\pi\sigma^2} \right)^{N/2} \exp \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^N (z_i - A)^2 \right]$$

$$\ln f(\mathbf{z}; A) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (z_i - A)^2$$

$$\frac{\partial \ln f(\mathbf{z}; A)}{\partial A} = \frac{1}{\sigma^2} \sum_{i=1}^N (z_i - A) = \frac{N}{\sigma^2} \left( \frac{1}{N} \sum_{i=1}^N z_i - A \right) \quad \hat{A}_{ml} = \bar{z} = \frac{1}{N} \sum_{i=1}^N z_i$$





## 7.3 最大似然估计

例7.6 高斯白噪声中的直流电平估计-未知参数与未知方差。

设有 $N$ 次独立观测 $z_i = A + v_i$ ， $i=1,2,\dots,N$ ，其中 $v \sim N(0, \sigma^2)$ ， $\sigma^2$ 、 $A$ 均为未知参数，求 $A$ 和 $\sigma^2$ 的最大似然估计。

【解】 令  $\theta = [A \ \sigma^2]^T$

$$f(\mathbf{z} | \boldsymbol{\theta}) = \left( \frac{1}{2\pi\sigma^2} \right)^{N/2} \exp \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^N (z_i - A)^2 \right]$$

$$\ln f(\mathbf{z}; \boldsymbol{\theta}) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (z_i - A)^2$$



## 7.3 最大似然估计

令

$$\frac{\partial \ln f(\mathbf{z}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \begin{bmatrix} \frac{N}{\sigma^2} \left( \frac{1}{N} \sum_{i=1}^N z_i - A \right) \\ -\frac{N}{2\sigma^4} \left[ \sigma^2 - \frac{1}{N} \sum_{i=1}^N (z_i - A)^2 \right] \end{bmatrix} = 0$$

得到：

$$\hat{\boldsymbol{\theta}}_{ml} = \begin{bmatrix} \hat{A}_{ml} \\ \hat{\sigma}^2 \end{bmatrix} = \begin{bmatrix} \bar{z} \\ \frac{1}{N} \sum_{i=1}^N (z_i - \bar{z})^2 \end{bmatrix}$$



估计问题的案例：时延估计 (time delay estimation)

通过案例


- 阐述估计的基本概念
- 分析求解估计问题的基本步骤
- 如何评估估计量的性能



## 7.8 信号处理实例

Problem:

How to determine the distance of target and sensor?



$$R = \frac{\tau_0 c}{2}$$

Also Be termed TOA (Time of Arrival)

Range estimation is equivalent to time delay estimation (TDE).



## 7.8 信号处理实例

### 问题的统计描述 (Problem of formulation )

The noise corrupted signals received by the radar over some time interval can be modeled as

$$z(t) = as(t - \tau_0) + v(t) \quad 0 \leq t \leq T$$


- How to develop an estimator to determine  $\tau_0$ ?
- How to evaluate the performance of the estimator?
- If  $a$  is unknown, how to estimate  $\tau_0$ ?



## 7.8 信号处理实例

### 步骤 1：将连续的观测离散化

假定噪声是零均值高斯过程，功率谱密度和相关函数分别为



$$R_v(\tau) = \int_{-B}^B G_v(f) df = N_0 B \frac{\sin(2\pi B\tau)}{2\pi B\tau}$$



## 7.8 信号处理实例

$$R_v(\tau) = N_0 B \frac{\sin(2\pi B\tau)}{2\pi B\tau}$$

如果对  $z(t)$  以  $\Delta = 1/(2B)$  进行抽样


$$z(n\Delta) = s(n\Delta - \tau_0) + v(n\Delta) \quad n = 0, 1, \dots, N-1$$

相互独立的噪声序列

$$z[n] = s(n\Delta - \tau_0) + v[n] \quad n = 0, 1, \dots, N-1$$



## 7.8 信号处理实例



$$z[n] = \begin{cases} v[n] & 0 \leq n \leq n_0 - 1 \\ s[n - n_0] + v[n] & n_0 \leq n \leq n_0 + M - 1 \\ v[n] & n_0 + M \leq n \leq N - 1 \end{cases}$$

The problem is changed to estimate  $n_0$






## 7.8 信号处理实例

### 步骤2：选择一种参数估计的方法

最大似然估计 (Maximum Likelihood Estimate) 是一种简单的估计。

定义：  $f(\mathbf{z}; \theta) \Big|_{\theta = \hat{\theta}_{ml}} = \max$


或  $\ln f(\mathbf{z}; \theta) \Big|_{\theta = \hat{\theta}_{ml}} = \max$



Probability of  $\theta$  lied in the interval is maximum



## 7.8 信号处理实例



$$\begin{aligned} f(\mathbf{z}; n_0) &= \prod_{n=0}^{N-1} f(z[n], n_0) \\ &= \prod_{n=0}^{n_0-1} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2} z^2[n]\right] \\ &\quad \cdot \prod_{n=n_0}^{n_0+M-1} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2} (z[n] - s[n - n_0])^2\right] \\ &\quad \cdot \prod_{n=n_0+M}^{N-1} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2} z^2[n]\right] \end{aligned}$$



## 7.8 信号处理实例

$$f(\mathbf{z}; n_0) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} z^2[n]\right] \\ \cdot \prod_{n=n_0}^{n_0+M-1} \exp\left[-\frac{1}{2\sigma^2} \left(-2z[n]s[n-n_0] + s^2[n-n_0]\right)\right]$$

Equivalently

$$\exp\left[-\frac{1}{2\sigma^2} \sum_{n=n_0}^{n_0+M-1} \left(-2z[n]s[n-n_0] + s^2[n-n_0]\right)\right] \quad \text{Maximizing}$$



$$\text{即} \quad \sum_{n=n_0}^{n_0+M-1} \left(-2z[n]s[n-n_0] + s^2[n-n_0]\right) \quad \text{Minimizing}$$



## 7.8 信号处理实例

由于

$$\sum_{n=n_0}^{n_0+M-1} s^2[n-n_0] = \sum_{n=0}^{N-1} s^2[n]$$





因此,  $n_0$  的MLE 可由使下式最大来求得

$$\sum_{n=n_0}^{n_0+M-1} z[n]s[n-n_0]$$

即

$$\hat{n}_0 = \arg \max_{n'_0} \left\{ \sum_{n=n'_0}^{n'_0+M-1} z[n]s[n-n'_0] \right\}$$

由于  $R=c\tau_0/2=cn_0\Delta/2$ , 所以距离的最大似然估计为


$$\hat{R} = (c\Delta/2)\hat{n}_0$$



## 7.8 信号处理实例

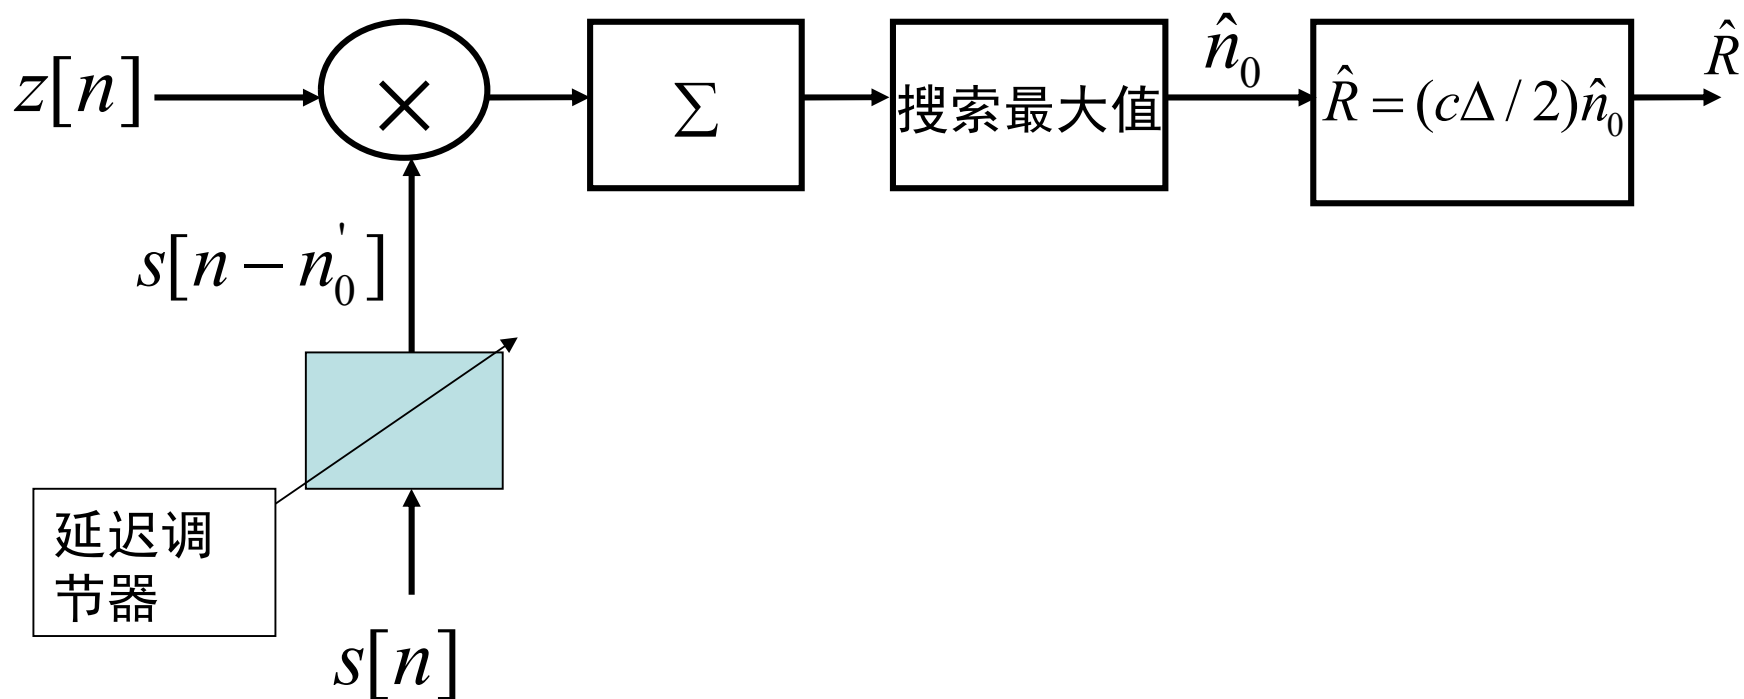
### 第三步：估计器的实现

$$\hat{n}_0 = \arg \max_{n'_0} \left\{ \sum_{n=n'_0}^{n'_0+M-1} z[n]s[n-n'_0] \right\}$$





## 7.8 信号处理实例



距离估计器的实现框图

## Step 3: Implement (Demonstration)

小程序查看器: Demo.DemoApplet.class

Applet

选择实验类型:

蒙特卡洛仿真    动态演示

参数设定:

采集数据长度T: 300

信号强度A: 2

噪声方差: 2

信号长度: 20

延迟长度: 178

循环的次数: 1000

运行

对所有的估计延迟进行统计:

均值: 178.043

方差: 1.6891509999999934

