



## 7.2 贝叶斯估计

后验概率

$$\int_{-\infty}^{\infty} C(\theta, \hat{\theta}(z)) f(\theta | z) d\theta = \text{最小}$$

代价函数

平方代价:  $C(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$   $\longrightarrow$   $\hat{\theta} = E[\theta | z]$

绝对值代价:  $C(\theta, \hat{\theta}) = |\theta - \hat{\theta}|$   $\longrightarrow$   $\int_{-\infty}^{\hat{\theta}_{abs}} f(\theta | z) d\theta = \int_{\hat{\theta}_{abs}}^{\infty} f(\theta | z) d\theta$


均匀代价:  $C(\theta, \hat{\theta}) = \begin{cases} 1, & |\theta - \hat{\theta}| \geq \frac{\Delta}{2} \\ 0, & |\theta - \hat{\theta}| < \frac{\Delta}{2} \end{cases}$   $\longrightarrow$   $\frac{\partial f(\theta | z)}{\partial \theta} \Big|_{\theta = \hat{\theta}_{map}} = 0$   
 $\frac{\partial \ln f(\theta | z)}{\partial \theta} \Big|_{\theta = \hat{\theta}_{map}} = 0$



## 7.3 最大似然估计

$$\left. \frac{\partial f(z | \theta)}{\partial \theta} \right|_{\theta = \hat{\theta}_{mL}} = 0$$

$$\left. \frac{\partial \ln f(z | \theta)}{\partial \theta} \right|_{\theta = \hat{\theta}_{mL}} = 0$$



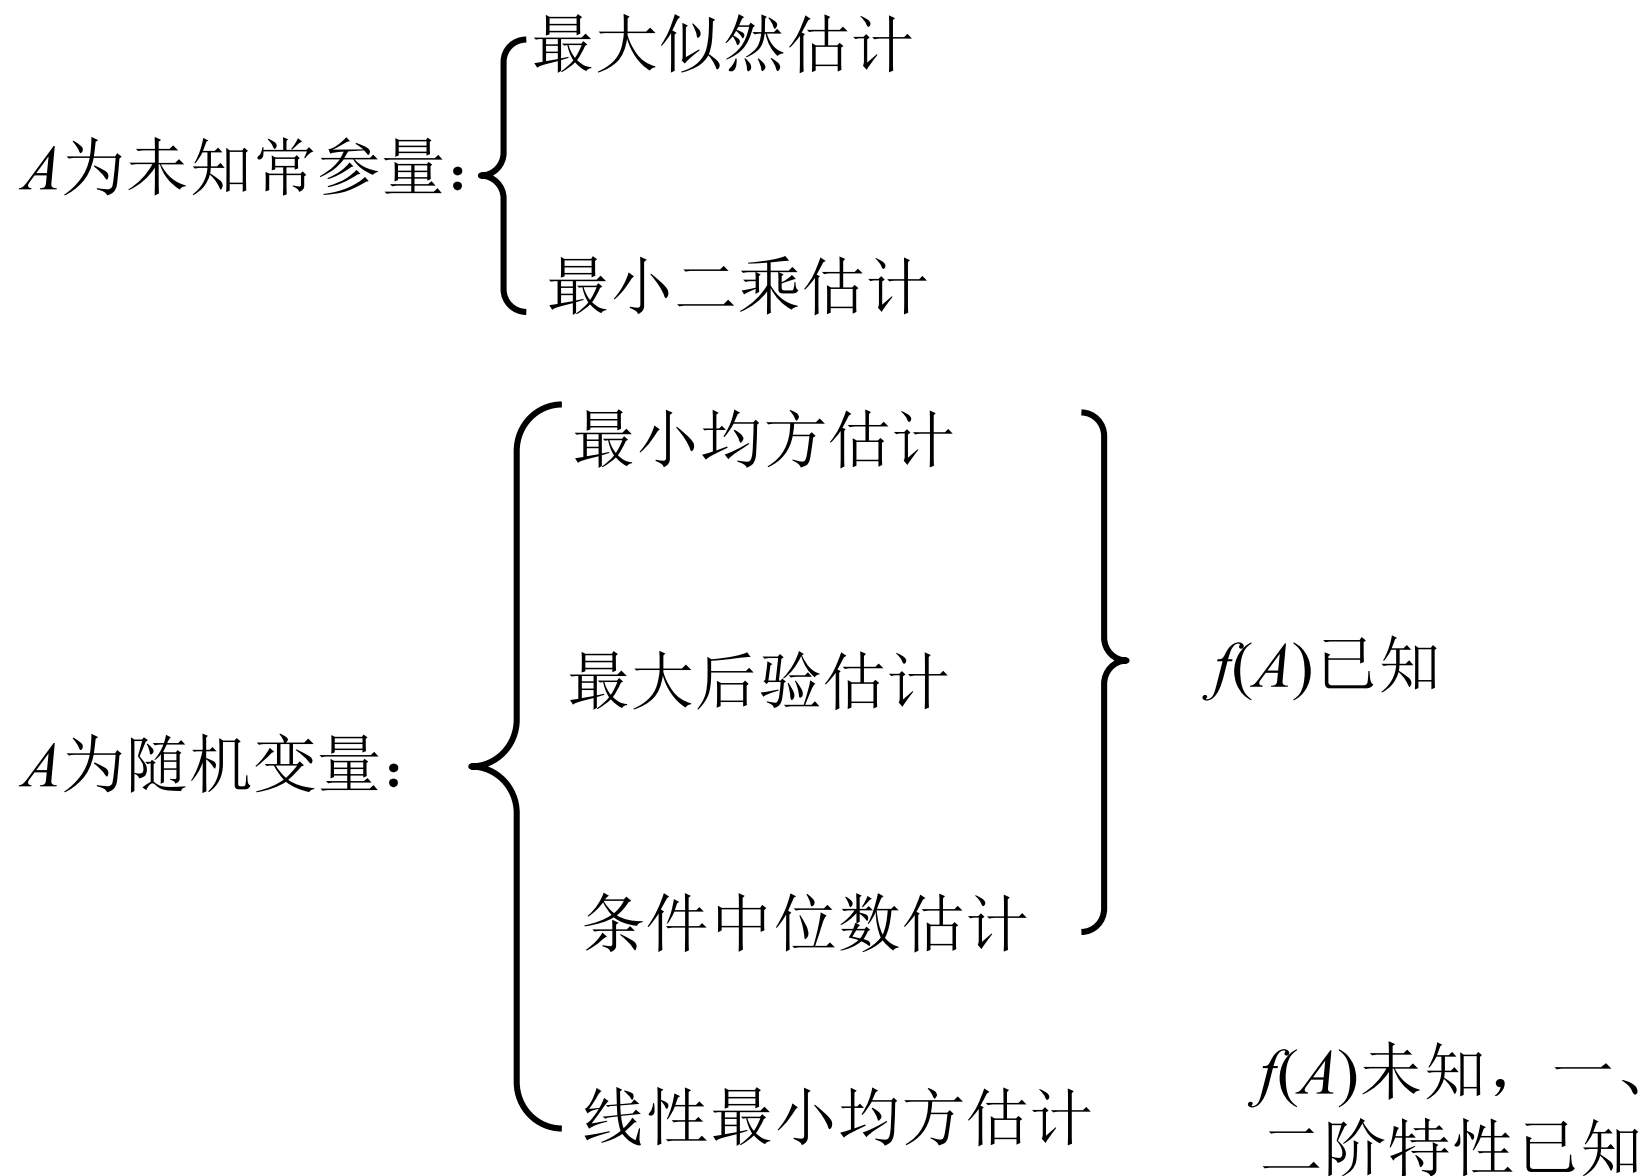


中山大學  
SUN YAT-SEN UNIVERSITY

习题： 7.7    7.15    7.19



## 各种方法的适应范围





### 复习相关概念：

1. 方差：刻画离散程度

$$D(\theta) = Var(\theta) = E[(\theta - m_\theta)^2] = E(\theta^2) - m_\theta^2$$

总体方差：

$$s^2 = \frac{1}{n} \sum_{i=1}^n (\theta_i - \bar{\theta})^2$$

样本方差：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$



## 7.4 估计量的性能

2. 均方误差 (MSE) 与均方根误差 (RMSE) : 刻画估计量与被估计量 (即真值) 之间的偏差

$$Mse(\hat{\theta}) = E\left[(\hat{\theta} - \theta)^2\right]$$

掌握!

**Classical:**  $mse(\hat{\theta}) = \int_{-\infty}^{\infty} (\theta - \hat{\theta})^2 f(\mathbf{z} | \theta) d\mathbf{z}$


**Bayesian:**  $Bmse(\hat{\theta}) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (\theta - \hat{\theta})^2 f(\mathbf{z}, \theta) d\mathbf{z} d\theta$

【交互】：首先为什么是  $\mathbf{z}, \theta$  的二维积分，为什么又能化为一维？



## 7.4 估计量的性能

如果用作图的方式来表现方差与均方误差之间的区别：



对于无偏估计，  
方差=均方差

### 3. 均方值 (MES) 与均方根值 (RMES)

$$E(X^2)$$

$$\frac{1}{n} \sum_{i=1}^n x_i^2$$





### 1 性能指标

无偏性、有效性、一致性

#### (1) 无偏性

若估计量的均值等于被估计量的均值，则

称此估计是无偏的，即  $E[\hat{\theta}(z)] = E[\theta]$

$$E[\hat{\theta}(z)] = \begin{cases} \theta & \theta \text{为确定性参量 (非随机参量)} \\ E[\theta] & \theta \text{为随机参量} \end{cases}$$



## 7.4 估计量的性能

当观测是多次测量时，这时估计量可表示为 $\hat{\theta} = \hat{\theta}(\mathbf{z}_N)$ ，

其中观测矢量为 $\mathbf{z}_N = [z_1, z_2, \dots, z_N]^T$ ，一般说来，观测数

据越多，估计的性能越好，对于有偏估计，如果

$$\lim_{N \rightarrow \infty} E[\hat{\theta}(\mathbf{z}_N)] = \begin{cases} \theta & \theta \text{为未知常量} \\ E(\theta) & \theta \text{为随机变量} \end{cases}$$

则称 $\hat{\theta}(\mathbf{z}_N)$ 为渐近无偏估计。



### (2) 有效性

对于无偏估计量，不同的估计一般具有不同的均方误差，均方误差越小越好。

若估计量的均方误差能达到最小方差，则此估计称为**有效估计 (ee)**。

对于非随机量，有：
$$Var(\hat{\theta}) = E\{[\hat{\theta} - \theta]^2\}$$

对于随机量，有：
$$Var(\hat{\theta}) = E\{[\hat{\theta} - E(\hat{\theta})]^2\}$$



### (3) 一致性

即对于任意小数 $\varepsilon$ , 若有:

$$\lim_{N \rightarrow \infty} P\left(\left|\hat{\theta}(z_1, z_2, \dots, z_N) - \theta\right| < \varepsilon\right) = 1$$

则估计量  $\hat{\theta}$  为一致估计量。

若满足  $\lim_{N \rightarrow \infty} E\left\{\left[\theta - \hat{\theta}(\mathbf{z}_N)\right]^2\right\} = 0$

则称  $\hat{\theta}$  为均方一致估计量。

## 7.4 估计量的性能

### 例：高斯白噪声中未知电平的估计

$$z_i = A + v_i \quad i = 1, 2, \dots, N \quad A \sim U(-A_0, A_0)$$

$\hat{A}_{map} = \begin{cases} -A_0 & \bar{z} < -A_0 \\ \bar{z} & A_0 \leq \bar{z} \leq A_0 \\ A_0 & \bar{z} > A_0 \end{cases}$	$\hat{A}_{ml} = \bar{z} = \frac{1}{N} \sum_{i=1}^N z_i$
$E(\hat{A}_{map}) \neq A$	$E(\hat{A}_{ml}) = E\left(\frac{1}{N} \sum_{i=1}^N z_i\right) = A$
$Mse(\hat{A}_{ml}) > Mse(\hat{A}_{map})$	

先验信息的利用，将有利于提高估计的性能



## 2、无偏估计量的性能边界

### (1) 非随机参量

假定满足正则条件  $E \left\{ \frac{\partial \ln f(\mathbf{z}; \theta)}{\partial \theta} \right\} = 0$

$$\text{Var}(\hat{\theta}) = E\{[\theta - \hat{\theta}]^2\} \geq I(\theta)^{-1}$$

克拉美-罗限

$$I(\theta) = E \left\{ \left[ \frac{\partial \ln f(\mathbf{z}; \theta)}{\partial \theta} \right]^2 \right\} = -E \left\{ \frac{\partial^2 \ln f(\mathbf{z}; \theta)}{\partial \theta^2} \right\}$$

等号成立的条件:  $\frac{\partial \ln f(\mathbf{z}; \theta)}{\partial \theta} = k(\theta)(\hat{\theta} - \theta)$



## 7.4 估计量的性能

【证明】设 $\hat{\theta}$ 是无偏估计，则有 $E(\hat{\theta} - \theta) = 0$ ，按照定义展开，即

$$E(\hat{\theta} - \theta) = \int_{-\infty}^{\infty} (\hat{\theta} - \theta) f(z|\theta) dz = 0$$

对 $\theta$ 求导，得到

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} (\hat{\theta} - \theta) f(z|\theta) dz = \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} [(\hat{\theta} - \theta) f(z|\theta)] dz = 0,$$

进一步有

$$-\int_{-\infty}^{\infty} f(z|\theta) dz + \int_{-\infty}^{\infty} \frac{\partial f(z|\theta)}{\partial \theta} (\hat{\theta} - \theta) dz = 0$$

由微分法则 $(\ln g(x))' = \frac{g'(x)}{g(x)}$ ，以及 $\int_{-\infty}^{\infty} f(z|\theta) dz = 1$ ，上式可以写为

$$\int_{-\infty}^{\infty} \frac{\partial \ln f(z|\theta)}{\partial \theta} f(z|\theta) (\hat{\theta} - \theta) dz = 1$$



## 7.4 估计量的性能

也可表示成

$$\int_{-\infty}^{\infty} \frac{\partial \ln f(z|\theta)}{\partial \theta} \sqrt{f(z|\theta)} \sqrt{f(z|\theta)} (\hat{\theta} - \theta) dz = 1$$

利用柯西-许瓦兹不等式

$$\left[ \int_{-\infty}^{\infty} f(x)g(x)dx \right]^2 \leq \int_{-\infty}^{\infty} f^2(x)dx \int_{-\infty}^{\infty} g^2(x)dx$$

可以有不等式成立：

$$1 \leq \underbrace{\int_{-\infty}^{\infty} \left[ \frac{\partial \ln f(z|\theta)}{\partial \theta} \right]^2 f(z|\theta) dz}_{E \left\{ \left[ \frac{\partial \ln f(z|\theta)}{\partial \theta} \right]^2 \right\} = I(\theta)} \times \underbrace{\int_{-\infty}^{\infty} (\hat{\theta} - \theta)^2 f(z|\theta) dz}_{\text{Var}(\hat{\theta})}$$





## 7.4 估计量的性能

由柯西-许瓦兹不等式 “=” 成立的条件，即

$$f(x) = kg(x)$$

可知，CRLB达到的条件，即等号成立的条件是

$$\frac{\partial \ln f(z|\theta)}{\partial \theta} = k(\theta)(\hat{\theta} - \theta)$$

【证毕】

此外，有

$$E\left\{\left[\frac{\partial \ln f(z|\theta)}{\partial \theta}\right]^2\right\} = -E\left\{\frac{\partial^2 \ln f(z|\theta)}{\partial \theta^2}\right\}$$



## 7.4 估计量的性能

【证明】

$$\int_{\{Z\}} f(\mathbf{z} | \theta) d\mathbf{z} = 1 \xRightarrow{\text{第一次求导}} \int_{\{Z\}} \frac{\partial f(\mathbf{z} | \theta)}{\partial \theta} d\mathbf{z} = \int_{\{Z\}} \frac{\partial \ln f(\mathbf{z} | \theta)}{\partial \theta} f(\mathbf{z} | \theta) d\mathbf{z} = 0$$

$$\xRightarrow{\text{第二次求导}} \int_{\{Z\}} \frac{\partial^2 \ln f(\mathbf{z} | \theta)}{\partial \theta^2} f(\mathbf{z} | \theta) d\mathbf{z} + \int_{\{Z\}} \left[ \frac{\partial \ln f(\mathbf{z} | \theta)}{\partial \theta} \right]^2 f(\mathbf{z} | \theta) d\mathbf{z} = 0$$

$$\Rightarrow E \left\{ \left[ \frac{\partial \ln f(\mathbf{z} | \theta)}{\partial \theta} \right]^2 \middle| \theta \right\} = -E \left[ \frac{\partial^2 \ln f(\mathbf{z} | \theta)}{\partial \theta^2} \middle| \theta \right]$$

【证毕】



### 几点说明：

(1) 定理成立的条件

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} (\hat{\theta} - \theta) f(z|\theta) dz \stackrel{?}{=} \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} [(\hat{\theta} - \theta) f(z|\theta)] dz = 0$$

- 定理成立的条件是求导和积分可交换
- 如果积分限与被估计量 $\theta$ 有关，则求导和积分就不能交换。
- CRLB定理不成立的情况：概率密度非零的区间与被估计量有关，如：概率密度为 $(0, \theta)$ 上均匀分布，而 $\theta$ 是被估计量。




## 7.4 估计量的性能

正则条件保证了上述要求，即

$$0 = E \left\{ \frac{\partial \ln f(\mathbf{z}|\theta)}{\partial \theta} \right\} = \int_{-\infty}^{\infty} \frac{\partial \ln f(\mathbf{z}|\theta)}{\partial \theta} f(\mathbf{z}|\theta) d\mathbf{z} = \int_{-\infty}^{\infty} \frac{\partial f(\mathbf{z}|\theta)}{\partial \theta} d\mathbf{z}$$

$$\text{且 } \frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} f(\mathbf{z}|\theta) d\mathbf{z} = 0 \quad \text{所以} \quad \int_{-\infty}^{\infty} \frac{\partial f(\mathbf{z}|\theta)}{\partial \theta} d\mathbf{z} = \frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} f(\mathbf{z}|\theta) d\mathbf{z}$$

(2)  $I(\theta)$  称为Fisher信息， $I$ 越大，越有可能得到好的估计。





## 7.4 估计量的性能

(3) 如果有效估计量存在，则该有效估计量一定是最大似然估计。

因为如果有效估计量存在，则表明满足

$$\frac{\partial \ln f(z|\theta)}{\partial \theta} = k(\theta)(\hat{\theta} - \theta)$$

而最大似然估计满足  $\left. \frac{\partial \ln f(z|\theta)}{\partial \theta} \right|_{\theta=\hat{\theta}_{ml}} = 0$

所以有  $k(\hat{\theta}_{ml})(\hat{\theta} - \hat{\theta}_{ml})=0$  即  $\hat{\theta} = \hat{\theta}_{ml}$

(4) 如果有效估计量不存在，则最大似然估计的方差不一定是最小的。



## 7.4 估计量的性能

例7.8 高斯白噪声中的DC电平。例子7.4中的ML估计是否达到了CRLB, 估计方差是多少?

$$z_i = A + v_i \quad i = 1, 2, \dots, N \quad v_i \sim N(0, \sigma^2)$$

$$\hat{A}_{ml} = \bar{z} = \frac{1}{N} \sum_{i=1}^N z_i$$

$$E[\hat{A}_{ml}] = E\left[\frac{1}{N} \sum_{i=1}^N z_i\right] = \frac{1}{N} \sum_{i=1}^N E[z_i] = A \quad \text{无偏估计}$$

$$\frac{\partial \ln f(\mathbf{z}; A)}{\partial A} = \frac{N}{\sigma^2} \left( \frac{1}{N} \sum_{i=1}^N z_i - A \right) = \frac{N}{\sigma^2} (\hat{A}_{ml} - A) \quad \text{达到了CRLB}$$

$$\text{Var}(\hat{A}_{ml}) = -\frac{1}{I} = \frac{\sigma^2}{N}$$



## 2、无偏估计量的性能边界

### (2) 随机参量

任何无偏估计量的均方误差满足

克拉美-罗限

$$Mse(\hat{\theta}) = E\{[\theta - \hat{\theta}]^2\} \geq J^{-1}$$

$$J = E\left\{\left[\frac{\partial \ln f(z, \theta)}{\partial \theta}\right]^2\right\} = -E\left\{\frac{\partial^2 \ln f(z, \theta)}{\partial \theta^2}\right\}$$

等号成立的条件:  $\frac{\partial \ln f(\mathbf{z}, \theta)}{\partial \theta} = k \cdot (\hat{\theta} - \theta)$  (式7.4.29)

注意,  $k$ 不是  $\mathbf{z}$  或者  $\theta$  的函数



## 7.4 估计量的性能

如果有某个无偏估计达到CRLB, 那么该估计必定是**最大后验概率**估计. 而最小均方估计的均方误差也是最小的, 所以这时最小均方估计与最大后验概率估计等价。

---

**例7.10** 高斯白噪声中的直流电平估计-高斯先验分布。设有N次独立观测 $z_i=A+v_i$ ,  $i=1, 2, \dots, N$ , 其中 $v \sim N(0, \sigma^2)$ ,  $A \sim N(\mu_A, \sigma_A^2)$ , 求A的估计的CRLB。

**【解】** 令 $\mathbf{z} = [z_1, z_2, z_3, \dots, z_N]$  求后验概率





## 7.4 估计量的性能

$$f(\mathbf{z}, A) = f(\mathbf{z} | A) f(A)$$

$$= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^N (z_i - A)^2\right] \frac{1}{\sqrt{2\pi\sigma_A^2}} \exp\left[-\frac{1}{2\sigma_A^2} (A - \mu_A)^2\right]$$

$$\ln f(\mathbf{z}, A) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (z_i - A)^2 - \frac{1}{2} \ln(2\pi\sigma_A^2) - \frac{1}{2\sigma_A^2} (A - \mu_A)^2$$

$$\frac{\partial \ln f(\mathbf{z}, A)}{\partial A} = \frac{1}{\sigma^2} \sum_{i=1}^N (z_i - A) - \frac{1}{\sigma_A^2} (A - \mu_A)$$

$$\stackrel{\text{参考7.3}}{=} \left( \frac{N}{\sigma^2} + \frac{1}{\sigma_A^2} \right) \left( \frac{\frac{N}{\sigma^2} \bar{z} + \frac{\mu_A}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} - A \right) = \left( \frac{N}{\sigma^2} + \frac{1}{\sigma_A^2} \right) (\hat{A}_{map} - A)$$

(7.4.34)



## 7.4 估计量的性能

其中 $\hat{A}_{map}$ 是例7.3中求得的A的最大后验概率估计，它可表示为

$$\hat{A}_{map} = \frac{\frac{N}{\sigma^2} \bar{z} + \frac{\mu_A}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}$$

它的均值为：

$$E(\hat{A}_{map}) = E\left(\frac{\frac{N}{\sigma^2} \bar{z} + \frac{\mu_A}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}\right) = \mu_A = E(A)$$

可见 $\hat{A}_{map}$ 是无偏估计。由(7.4.34)式可以看出， $\hat{A}_{map}$ 满足(7.4.29)式，因此，它的均方误差等于CRLB。又



## 7.4 估计量的性能

$$\frac{\partial^2 \ln f(\mathbf{z}, A)}{\partial A^2} = -\frac{N}{\sigma^2} - \frac{1}{\sigma_A^2}$$

$$Mse(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \left( \frac{N}{\sigma^2} + \frac{1}{\sigma_A^2} \right)^{-1} = \frac{\sigma_A^2 \sigma^2}{N\sigma_A^2 + \sigma^2}$$

**总结：**有效估计量是建立在无偏的基础上的，因为克拉美—罗不等式取等号的条件，都是在任意无偏估计量基础上导出的。