



1. 方差：刻画离散程度

$$D(\theta) = \text{Var}(\theta) = E[(\theta - m_\theta)^2] = E(\theta^2) - m_\theta^2$$

2. 均方误差（MSE）与均方根误差（RMSE）：刻画估计量与被估计量（即真值）之间的偏差


$$Mse(\hat{\theta}) = E\left[(\hat{\theta} - \theta)^2\right]$$

Classical: $mse(\hat{\theta}) = \int_{-\infty}^{\infty} (\theta - \hat{\theta})^2 f(\mathbf{z} | \theta) d\mathbf{z}$

Bayesian: $Bmse(\hat{\theta}) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (\theta - \hat{\theta})^2 f(\mathbf{z}, \theta) d\mathbf{z} d\theta$



如果用作图的方式来表现方差与均方误差之间的区别：



对于无偏估计，
方差=均方差

【问题解答】 如何理解P210的结论和例子7.8的关系？

例子7.8中说，噪声中恒定电平的ML估计是无偏的，且达到了CRLB下限，是有效估计，但是P210也有说它不如Map估计。



1 性能指标

无偏性、有效性、一致性

(1) 无偏性

若估计量的均值等于被估计量的均值，则

称此估计是无偏的，即 $E[\hat{\theta}(z)] = E[\theta]$

$$E[\hat{\theta}(z)] = \begin{cases} \theta & \theta \text{为确定性参量 (非随机参量)} \\ E[\theta] & \theta \text{为随机参量} \end{cases}$$



(2) 有效性

若估计量的均方误差能达到最小方差，则此估计称为**有效估计**（ee）。

(3) 一致性

即对于任意小数 ε ，若有：

$$\lim_{N \rightarrow \infty} P\left(\left|\hat{\theta}(z_1, z_2, \dots, z_N) - \theta\right| < \varepsilon\right) = 1$$

则估计量 $\hat{\theta}$ 为**一致**估计量。



2、无偏估计量的性能边界

(1) 非随机参量

假定满足正则条件 $E \left\{ \frac{\partial \ln f(\mathbf{z}; \theta)}{\partial \theta} \right\} = 0$

$$\text{Var}(\hat{\theta}) = E\{[\theta - \hat{\theta}]^2\} \geq I(\theta)^{-1} \quad \text{克拉美-罗限}$$

$$I(\theta) = E \left\{ \left[\frac{\partial \ln f(\mathbf{z}; \theta)}{\partial \theta} \right]^2 \right\} = -E \left\{ \frac{\partial^2 \ln f(\mathbf{z}; \theta)}{\partial \theta^2} \right\}$$

等号成立的条件: $\frac{\partial \ln f(\mathbf{z}; \theta)}{\partial \theta} = k(\theta)(\hat{\theta} - \theta)$



几点说明：

(1) 定理成立的条件

正则条件保证了上述要求，即 $E \left\{ \frac{\partial \ln f(\mathbf{z}|\theta)}{\partial \theta} \right\} = 0$

(2) $I(\theta)$ 称为Fisher信息， I 越大，越有可能得到好的估计。

(3) 如果有效估计量存在，则该有效估计量一定是最大似然估计。

(4) 如果有效估计量不存在，则最大似然估计的方差不一定是最小的。



2、无偏估计量的性能边界

(2) 随机参量

任何无偏估计量的均方误差满足

克拉美-罗限

$$Mse(\hat{\theta}) = E\{[\theta - \hat{\theta}]^2\} \geq J^{-1}$$

$$J = E\left\{\left[\frac{\partial \ln f(z, \theta)}{\partial \theta}\right]^2\right\} = -E\left\{\frac{\partial^2 \ln f(z, \theta)}{\partial \theta^2}\right\}$$

等号成立的条件: $\frac{\partial \ln f(\mathbf{z}, \theta)}{\partial \theta} = k \cdot (\hat{\theta} - \theta)$ (式7.4.29)

注意, k 不是 \mathbf{z} 或者 θ 的函数



中山大學
SUN YAT-SEN UNIVERSITY

复习

如果有某个无偏估计达到CRLB, 那么该估计必定是**最大后验概率**估计. 而最小均方估计的均方误差也是最小的, 所以这时最小均方估计与最大后验概率估计等价。



中山大學
SUN YAT-SEN UNIVERSITY

习题： 8.2



7.5 线性最小均方估计

1、线性最小均方估计(linear minimum mean square error estimation) (要求：一般性掌握)

、前提：不知道 $f(\theta)$ ，知道 θ 的一、二阶矩特性

准则：使均方误差最小的线性估计

实现：
$$\hat{\theta}_{lms} = \sum_{i=1}^N a_i z_i + b$$

选择适当的系数 a_i 及 b ，使估计均方误差最小。

$$Mse(\hat{\theta}) = E[(\theta - \hat{\theta})^2] = E \left[\left(\theta - \sum_{i=1}^N a_i z_i - b \right)^2 \right] = \min$$

【交互】属于哪一类方法？



均方误差对系数求导，并令导数等于零，得

$$\frac{\partial Mse(\hat{\theta})}{\partial b} = -2E\left[\left(\theta - \sum_{i=1}^N a_i z_i - b\right)\right] = 0 \quad (3)$$

$$\frac{\partial Mse(\hat{\theta})}{\partial a_j} = -2E\left[\left(\theta - \sum_{i=1}^N a_i z_i - b\right)z_j\right] = 0, \quad j=1,2,\dots,N \quad (4)$$

经整理后得：

$$\begin{cases} b = E[\theta] - \sum_{i=1}^N a_i E[z_i] \\ E\left[\left(\theta - \sum_{i=1}^N a_i z_i - b\right)z_j\right] = 0 \end{cases} \quad (5)$$

列方程求解



7.5 线性最小均方估计

$$E[\tilde{\theta} z_j] = E[(\theta - \hat{\theta}_{lms}) z_j] = 0$$

正交条件

正交条件是信号最佳线性滤波和估计算法的基础，在随机信号处理中占有十分重要的地位。

无偏+正交 \longleftrightarrow Lms估计



性能分析:

👉 线性最小均方估计为无偏估计，即有：

$$E\left[\hat{\theta}_{lms}\right] = E\left[\theta\right]$$

👉 线性最小均方估计的均方误差等于误差与被估计量乘积的统计均值，即：

$$E\left[\tilde{\theta}^2\right] = E\left[\tilde{\theta}\theta\right]$$

其中： $\tilde{\theta} = \theta - \hat{\theta}_{lms}$



例7.11、设观测模型为 $\mathbf{z}_i = \mathbf{s} + \mathbf{v}_i$ ， $i=1,2,\dots$ ，其中随机参量 \mathbf{s} 以等概率取 $\{-2,-1,0,1,2\}$ 诸值，噪声干扰 \mathbf{v}_i 以等概率取 $\{-1,0,1\}$ 诸值，且 $\mathbf{E}[\mathbf{s}\mathbf{v}_i] = \mathbf{0}$ ， $\mathbf{E}[\mathbf{v}_i\mathbf{v}_j] = \sigma_v^2 \delta_{ij}$ ，试根据一次、二次、三次观测数据求参量 \mathbf{s} 的线性最小均方估计。

【解】 根据给定的条件，可以求得

$$\mathbf{E}(\mathbf{s}) = (-2-1+0+1+2)/5=0$$

$$\mathbf{E}(\mathbf{s}^2) = [(-2) \times (-2) + (-1) \times (-1) + 0 \times 0 + 1 \times 1 + 2 \times 2]/5=2$$

$$\sigma_s^2 = \mathbf{E}(\mathbf{s}^2) = [(-2) \times (-2) + (-1) \times (-1) + 0 \times 0 + 1 \times 1 + 2 \times 2]/5=2$$

$$\mathbf{E}(\mathbf{v}_i) = (-1+0+1)/3=0$$



7.5 线性最小均方估计

$$\sigma_v^2 = E(v_i^2) = [(-1) \times (-1) + 0 \times 0 + 1 \times 1]/3 = 2/3$$

$$E(z_i) = E(s) + E(v_i) = 0$$

$$E(sz_i) = E[s(s + v_i)] = E(s^2) = 2$$

$$E(z_i^2) = E[(s + v_i)^2] = E(s^2) + E(v_i^2) = 8/3$$

(1) 一次观测数据, 令 $\hat{s}_{lms} = a_1 z_1 + b$,

由前式(5), $b = E(s) - a_1 E(z_1)$

$$E[(s - a_1 z_1)z_1] = 0 \quad (\text{正交条件})$$

$$b=0, \quad a_1 = \frac{E(sz_1)}{E(z_1^2)} = \frac{2}{8/3} = \frac{3}{4}$$

所以,
$$\hat{s}_{lms} = \frac{3}{4} z_1$$



7.5 线性最小均方估计

估计的均方误差为： $E[\tilde{s}^2] = E[\tilde{s}s] = E[(s - a_1 z_1)s] =$

$$E(s^2) - a_1 E[sz_1] = 2 - \frac{3}{4} \times 2 = \frac{1}{2}$$

(2) 二次观测数据

$$\text{令 } \hat{s}_{lms} = a_1 z_1 + a_2 z_2 + b$$

$$b = E(s) - a_1 E(z_1) - a_2 E(z_2) = 0$$

由正交条件， $E[(s - a_1 z_1 - a_2 z_2)z_1] = 0$ ， $E[(s - a_1 z_1 - a_2 z_2)z_2] = 0$

代入各数值， $2 - \frac{8}{3}a_1 - 2a_2 = 0$ ， $2 - 2a_1 - \frac{8}{3}a_2 = 0$ ，解方

程得 $a_1 = a_2 = \frac{3}{7}$



7.5 线性最小均方估计

所以，线性最小均方估计为： $\hat{s}_{lms} = \frac{3}{7}(z_1 + z_2)$

估计的均方误差为：

$$\begin{aligned} E(\tilde{s}^2) &= E(\tilde{s}s) = E[(s - a_1 z_1 - a_2 z_2)s] = E(s^2) - a_1 E(sz_1) - a_2 E(sz_2) \\ &= 2 - \frac{3}{7} \times 2 - \frac{3}{7} \times 2 = \frac{2}{7} \end{aligned}$$

(3) 三次观测数据

通过类似的计算步骤，可以求得： $\hat{s}_{lms} = \frac{3}{10}(z_1 + z_2 + z_3)$

估计的均方误差为： $E(\tilde{s}^2) = \frac{1}{5}$

从本例可以看出，观测数据越多，估计的均方误差越小。【完毕】



7.5 线性最小均方估计

更一般地，对于多参量的估计，用矢量表示估计将更为方便。设待估计量为 $\boldsymbol{\theta} = [\theta_1, \theta_2, \dots, \theta_n]^T$ ，观测矢量为 $\mathbf{z} = [z_1, z_2, \dots, z_m]^T$ ，线性估计可表示为

$$\hat{\boldsymbol{\theta}} = \mathbf{A}\mathbf{z} + \mathbf{b} \quad (8)$$

其中 \mathbf{b} 是 $n \times 1$ 的矢量， \mathbf{A} 是 $n \times m$ 的矩阵，所有估计的均方误差和可表示为

$$Mse(\hat{\boldsymbol{\theta}}) = E\left[\sum_{i=1}^N (\theta_i - \hat{\theta}_i)^2\right] = E[(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}})^T (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}})] \quad (9)$$

将(8)代入(9)，得

$$Mse(\hat{\boldsymbol{\theta}}) = E[(\boldsymbol{\theta} - \mathbf{A}\mathbf{z} - \mathbf{b})^T (\boldsymbol{\theta} - \mathbf{A}\mathbf{z} - \mathbf{b})] \quad (10)$$

分别对 \mathbf{A} 和 \mathbf{b} 求导并令导数等于零，得



7.5 线性最小均方估计

$$\frac{\partial Mse(\hat{\theta})}{\partial \mathbf{b}} = -2E[\boldsymbol{\theta} - \mathbf{A}\mathbf{z} - \mathbf{b}] = \mathbf{0} \quad (11)$$

$$\frac{\partial Mse(\hat{\theta})}{\partial \mathbf{A}} = -2E\{[\boldsymbol{\theta} - \mathbf{A}\mathbf{z} - \mathbf{b}]\mathbf{z}^T\} = \mathbf{0} \quad (12)$$

由(11)和(12)得,

$$\mathbf{b} = E[\boldsymbol{\theta}] - \mathbf{A}E[\mathbf{z}] \quad (13)$$

$$\mathbf{A} = \mathbf{P}_{\boldsymbol{\theta}\mathbf{z}}\mathbf{P}_{\mathbf{z}\mathbf{z}}^{-1} \quad (14)$$

$$\text{其中, } \mathbf{P}_{\boldsymbol{\theta}\mathbf{z}} = cov(\boldsymbol{\theta}, \mathbf{z}) = E\{[\boldsymbol{\theta} - E(\boldsymbol{\theta})][\mathbf{z} - E(\mathbf{z})]^T\} \quad (15)$$

$$\mathbf{P}_{\mathbf{z}} = Var(\mathbf{z}) = E\{[\mathbf{z} - E(\mathbf{z})][\mathbf{z} - E(\mathbf{z})]^T\} \quad (16)$$

线性最小均方估计为

只与一、二阶矩有关!

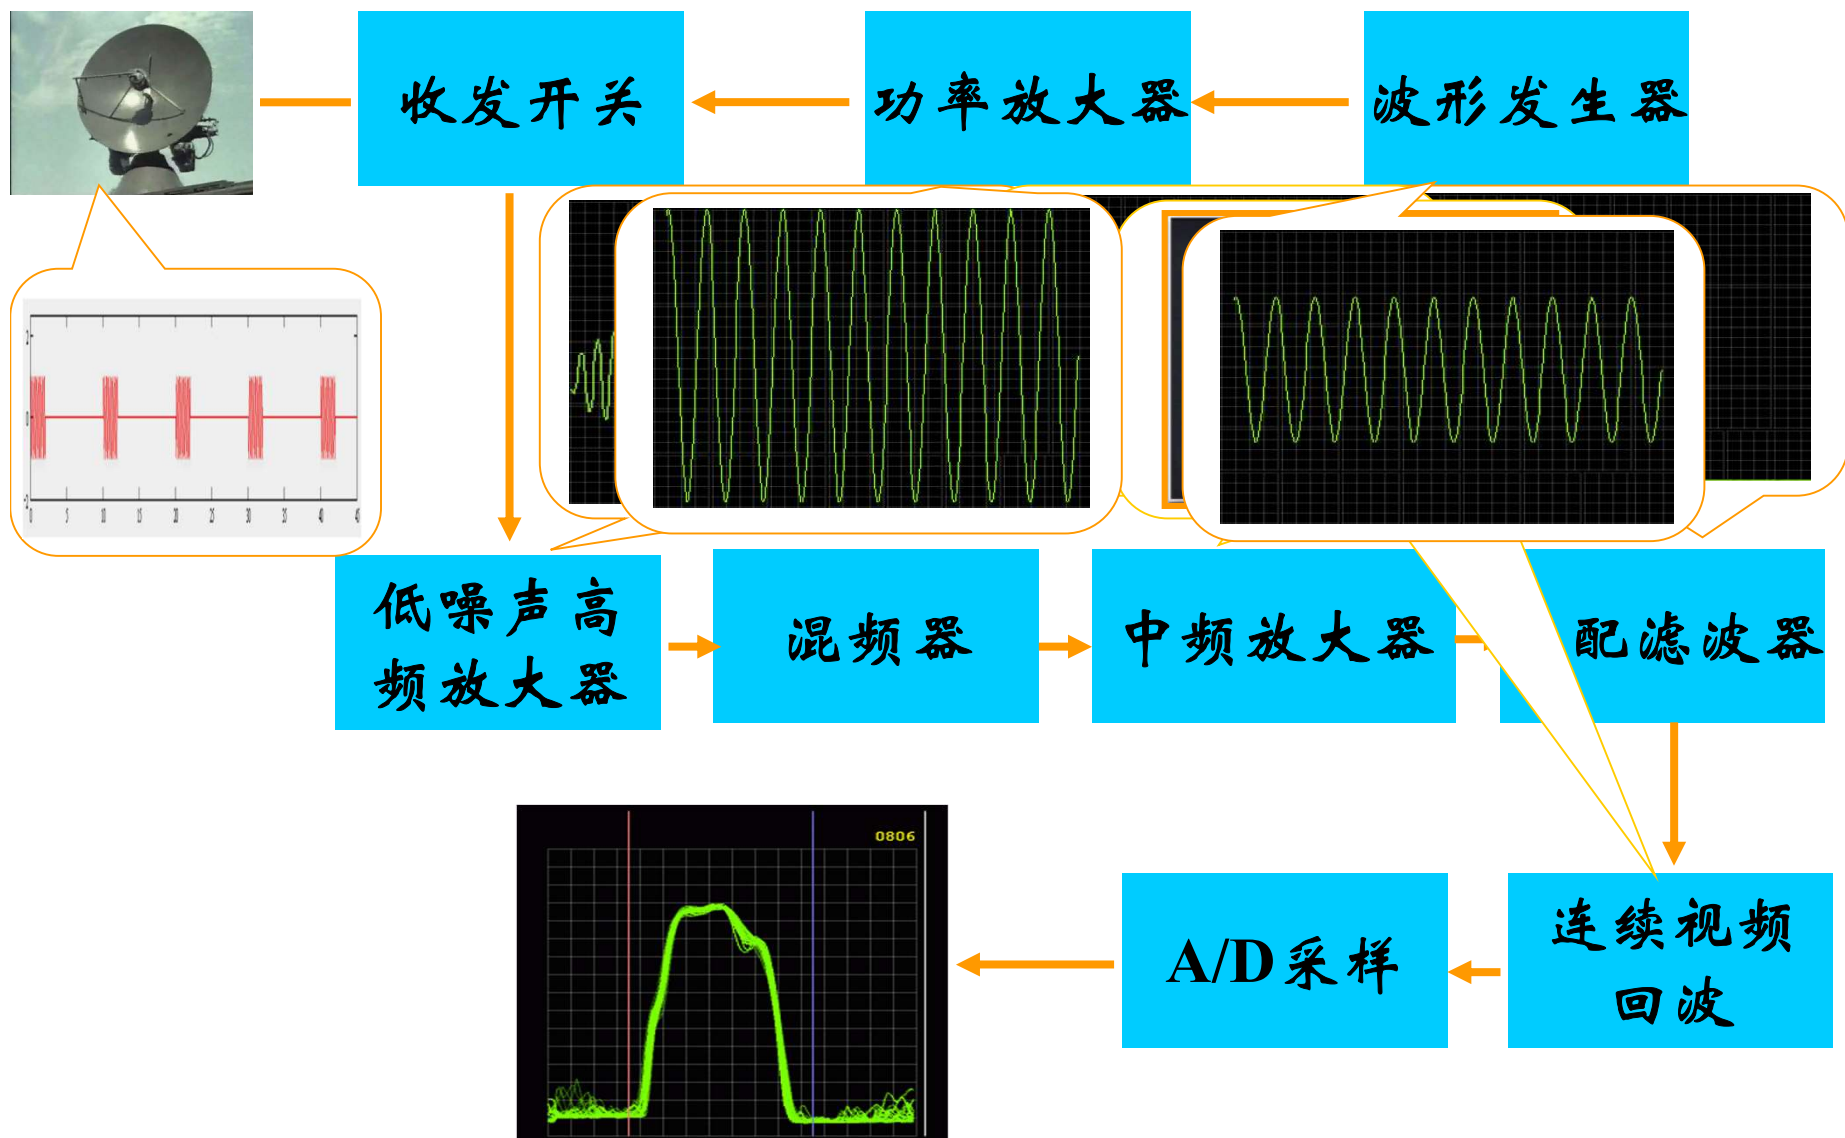
$$\hat{\boldsymbol{\theta}}_{lms} = E[\boldsymbol{\theta}] + \mathbf{P}_{\boldsymbol{\theta}\mathbf{z}}\mathbf{P}_{\mathbf{z}}^{-1}[\mathbf{z} - E(\mathbf{z})] \quad (17)$$



中山大學
SUN YAT-SEN UNIVERSITY

第八章 检测理论

雷达系统:





中山大學
SUN YAT-SEN UNIVERSITY

第八章 检测理论

8.1 假设检验的基本概念（重点）

8.2 判决准则（重点）

8.3 检测性能及其蒙特卡罗仿真

8.4 复合假设检验

8.6 噪声中信号的检测



8.1 假设检验的基本概念

假设：对可能的判决结果的陈述；

雷达目标检测： H_1 ：“Target present”


H_0 ：“Target not present”

假设检验：对几种可能的假设作出判决；

- H_1 和 H_0 是互不相容的，这是最简单的**二元假设**问题，对两种假设进行判决称为**二元假设检验**问题；
- 更一般的问题是有M个假设，称为**M元假设**问题，对M个假设进行判决称为**M元假设检验**问题。



8.1 假设检验的基本概念



假设检验的实质是对观测空间进行划分。



中山大學
SUN YAT-SEN UNIVERSITY

8.1 假设检验的基本概念

借助假设检验进行统计判决，步骤如下：

- 作出合理的假设；
- 选择进行判决时所遵循的判决准则；
- 获取观测样本；
- 作出具体判决。




1、最大后验概率准则

在观测到数据 \mathbf{z} 的情况下，可以计算出后验概率 $P(H_1|\mathbf{z})$ 和 $P(H_0|\mathbf{z})$ ，对二个后验概率进行比较，判定后验概率大所对应的那个假设成立，则判决公式为：

$$\frac{P(H_1 | z)}{P(H_0 | z)} \geq 1 \quad \text{判决 } H_1 \text{ 成立}$$

$$\frac{P(H_1 | z)}{P(H_0 | z)} < 1 \quad \text{判决 } H_0 \text{ 成立}$$



$$\frac{P(H_1 | z)}{P(H_0 | z)} \underset{H_0}{\overset{H_1}{>}} 1$$



8.2 判决准则

利用贝叶斯公式: $P(H_i | z) = \frac{P(H_i)f(z | H_i)}{f(z)}$

$$\frac{P(H_1 | z)}{P(H_0 | z)} = \frac{f(z | H_1)P(H_1)}{f(z | H_0)P(H_0)}$$

似然比

门限

$$\frac{P(H_1 | z)}{P(H_0 | z)} \underset{H_0}{\overset{H_1}{>}} 1 \longrightarrow \Lambda(z) \triangleq \frac{f(z | H_1)}{f(z | H_0)} \underset{H_0}{\overset{H_1}{>}} \frac{P(H_0)}{P(H_1)} = \eta_0$$

假设检验问题转化为似然比与门限进行比较的问题，称为似然比检验



8.2 判决准则

对于二元假设检验，有四种可能结果

H_0 为真，判 H_0 成立	——正确判决
H_1 为真，判 H_1 成立	——正确检测
H_0 为真，判 H_1 成立	——虚警（第一类错误）
H_1 为真，判 H_0 成立	——漏警（第二类错误）

发现概率或检测概率: $P_D = P(D_1 | H_1) = \int_{Z_1} f(z | H_1) dz$

虚警概率(常用 α 表示): $P_F = P(D_1 | H_0) = \int_{Z_1} f(z | H_0) dz = \alpha$

漏警概率(常用 β 表示): $P_M = P(D_0 | H_1) = \int_{Z_0} f(z | H_1) dz = \beta$



例8.1: 二元假设:

$$H_1: \mathbf{z} = \mathbf{1} + \mathbf{v}$$

$$H_0: \mathbf{z} = \mathbf{v}$$

其中 \mathbf{v} 是均值为零、方差为 $\mathbf{1}$ 的正态随机变量; 假定 $P(H_0) = P(H_1)$
给出**最大后验概率判决式**, 并确定判决性能。

【解】 最大后验概率准则的判决表达式是似然比检验的形式,
因此首先计算似然比,

$$f(z|H_0) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right), \quad f(z|H_1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(z-1)^2}{2}\right)$$

$$\Lambda(z) = \frac{f(z|H_1)}{f(z|H_0)} = \exp\left(z - \frac{1}{2}\right)$$



8.2 判决准则

所以判决表达式为：

$$\exp\left(z - \frac{1}{2}\right) \underset{H_0}{\overset{H_1}{>}} 1$$

对上式两边取对数为：

$$z \underset{H_0}{\overset{H_1}{>}} \frac{1}{2}$$

在本例中，观测空间 $Z = (-\infty, \infty)$ ， H_0 的判决域为 $Z_0 = (-\infty, 1/2)$ ， H_1 的判决域为 $Z_1 = (1/2, \infty)$ ，判决的虚警概率为：

$$P_F = P(D_1|H_0) = \int_{\frac{1}{2}}^{\infty} f(z|H_0)dz = Q(1/2)$$

漏警概率： $P_M = P(D_0|H_1) = \int_{-\infty}^{\frac{1}{2}} f(z|H_1)dz = Q(1/2)$

检测概率： $P_D = P(D_1|H_1) = 1 - P_M = 1 - Q(1/2)$



8.2 判决准则

对于多次测量，只需把测量 z 改写成矢量形式 \mathbf{z} 就可以了：

$$\Lambda(\mathbf{z}) \underset{H_0}{\overset{H_1}{>}} \eta_0 \quad (3)$$

其中，
$$\Lambda(\mathbf{z}) = \frac{f(\mathbf{z}|H_1)}{f(\mathbf{z}|H_0)} = \frac{f(z_1, z_2, \dots, z_N|H_1)}{f(z_1, z_2, \dots, z_N|H_0)}$$

虚警概率为：

$$P_F = \int_{Z_1} f(\mathbf{z}|H_0) d\mathbf{z} = \int_{Z_1} f(z_1, z_2, \dots, z_N|H_0) dz_1 dz_2 \cdots dz_N$$

漏警概率为：

$$P_M = \int_{Z_0} f(\mathbf{z}|H_1) d\mathbf{z} = \int_{Z_0} f(z_1, z_2, \dots, z_N|H_1) dz_1 dz_2 \cdots dz_N$$



2、贝叶斯准则

已知信号的先验概率和代价因子，使统计平均代价最小。

统计平均代价：

$$C = \sum_{i=0}^1 \sum_{j=0}^1 C_{ij} P(D_i, H_j) = \min$$

代价因子 C_{ij} 表示 H_j 为真，判决为 H_i 所付出的代价。

简单推导，有

$$\begin{aligned} C &= C_{10}P(H_0) + C_{11}P(H_1) \\ &+ \int_{Z_0} [P(H_1)(C_{01} - C_{11})f(z | H_1) - P(H_0)(C_{10} - C_{00})f(z | H_0)] dz \end{aligned}$$



8.2 判决准则

如果

$$P(H_1)(C_{01} - C_{11})f(z | H_1) < P(H_0)(C_{10} - C_{00})f(z | H_0)$$

判 H_0 成立，否则判 H_1 成立。

判决表达式为：

假设检验问题转化似然比检验

似然比

$$\frac{f(z | H_1)}{f(z | H_0)} \underset{H_0}{\overset{H_1}{\geq}} \frac{P(H_0)(C_{10} - C_{00})}{P(H_1)(C_{01} - C_{11})}$$

门限



3、最小总错误概率准则

在已知信号的先验概率 $P(H_1)$ 和 $P(H_0)$ 的条件下，使总错误概率最小：

$$P_e = P(D_1, H_0) + P(D_0, H_1) = P_F P(H_0) + P_M P(H_1) = \min$$

常应用在数字通信中。相当于贝叶斯准则中

$$C_{00} = C_{11} = 0, C_{01} = C_{10} = 1。$$

最大后验概率判决式

$$\text{判决规则为: } \Lambda(z) \underset{H_0}{\overset{H_1}{\gtrless}} \eta_0 = \frac{P(H_0)}{P(H_1)}$$

假设检验问题转化似然比检验



8.2 判决准则

例8.2 高斯白噪声中直流电平的检测问题。设有两种假设

$$H_0: \quad z_i = v_i, \quad i=1, 2, \dots, N$$

$$H_1: \quad z_i = A + v_i, \quad i=1, 2, \dots, N$$

其中 $\{v_i\}$ 是服从均值为零、方差为 σ^2 的高斯白噪声序列，假定参数 A 是已知的，且 $A > 0$ ，求贝叶斯准则（或最小总错误概率准则）的判决表达式，并确定判决性能。

【解】 两种假设下的似然函数为：
$$f(\mathbf{z}|H_0) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{z_i^2}{2\sigma^2}\right)$$

$$f(\mathbf{z}|H_1) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(z_i - A)^2}{2\sigma^2}\right]$$



8.2 判决准则

$$\Lambda(\mathbf{z}) = \frac{\prod_{i=1}^N \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(z_i - A)^2}{2\sigma^2}\right]}{\prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{z_i^2}{2\sigma^2}\right)} = \exp\left[\frac{NA}{\sigma^2} \left(\frac{1}{N} \sum_{i=1}^N z_i - \frac{1}{2}A\right)\right]$$

对数似然比为: $\ln \Lambda(\mathbf{z}) = \frac{NA}{\sigma^2} \left(\frac{1}{N} \sum_{i=1}^N z_i - \frac{1}{2}A\right)$

判决表达式为: $\frac{NA}{\sigma^2} \left(\frac{1}{N} \sum_{i=1}^N z_i - \frac{1}{2}A\right) \begin{matrix} H_1 \\ > \\ < \end{matrix} \ln \eta_0$

令 $\bar{z} = \frac{1}{N} \sum_{i=1}^N z_i$, 将上式整理后得: $\bar{z} \begin{matrix} H_1 \\ > \\ < \\ H_0 \end{matrix} \frac{\sigma^2}{NA} \ln \eta_0 + \frac{1}{2}A = \gamma$



8.2 判决准则

检验统计量 \bar{z} 为样本均值，为了确定判决的性能，首先需要确定检验统计量的分布，在 H_0 为真时， $\bar{z}|H_0 = \frac{1}{N} \sum_{i=1}^N v_i$ ，那么，

$$f_{\bar{z}}(\bar{z}|H_0) = \frac{1}{\sqrt{2\pi\sigma^2/N}} \exp\left(-\frac{\bar{z}^2}{2\sigma^2/N}\right)$$

在 H_1 为真时， $\bar{z}|H_1 = \frac{1}{N} \sum_{i=1}^N (A + v_i) = A + \frac{1}{N} \sum_{i=1}^N v_i$

$$f_{\bar{z}}(\bar{z}|H_1) = \frac{1}{\sqrt{2\pi\sigma^2/N}} \exp\left(-\frac{(\bar{z}-A)^2}{2\sigma^2/N}\right)$$

$$\begin{aligned} \text{检测概率 } P_D &= P(\bar{z} > \gamma | H_1) = \int_{\gamma}^{\infty} \frac{1}{\sqrt{2\pi\sigma^2/N}} \exp\left(-\frac{(\bar{z}-A)^2}{2\sigma^2/N}\right) d\bar{z} \\ &= Q\left(\frac{\sqrt{N}(\gamma - A)}{\sigma}\right) \end{aligned}$$



8.2 判决准则

当采用最小错误概率准则且 $P(H_1)=P(H_0)$ 时, $\eta_0=1$, 判决表达式为

$$\bar{z} \begin{matrix} H_1 \\ > \\ < \\ H_0 \end{matrix} \frac{1}{2}A = \gamma$$

$$P_F = Q\left(\frac{\sqrt{NA}}{2\sigma}\right), \quad P_D = Q\left(-\frac{\sqrt{NA}}{2\sigma}\right) = 1 - Q\left(\frac{\sqrt{NA}}{2\sigma}\right)$$

总的错误概率为: $P_e = P(H_0)P_F + P(H_1)P_M = Q\left(\frac{\sqrt{NA}}{2\sigma}\right)$